

---

# StyleDrive：面向端到端自动驾驶驾驶风格感知的基准测试

---

Ruiyang Hao<sup>1,2</sup>, Bowen Jing<sup>3</sup>, Haibao Yu<sup>1,4</sup>, Zaiqing Nie<sup>1,\*</sup>

<sup>1</sup> AIR, Tsinghua University <sup>2</sup> King's College London

<sup>3</sup> The University of Manchester <sup>4</sup> The University of Hong Kong

<https://styledrive.github.io/>

## Abstract

个性化问题虽然在传统自动驾驶流水线中得到了广泛研究，但在端到端自动驾驶 (E2EAD) 背景下却长期被忽视，尽管其在增强用户信任、安全感知和现实世界应用方面起着至关重要的作用。一个主要瓶颈在于缺乏大规模真实世界数据集来系统性地捕捉驾驶偏好，严重制约了个性化 E2EAD 模型的开发与评估。本文首次提出一个大规模真实世界数据集，专门针对个性化 E2EAD 进行构建，整合了全面的场景拓扑结构，并融合了通过微调视觉-语言模型 (VLM) 推断出的智能体动态与语义信息所形成的丰富动态上下文。我们提出一种混合标注流水线，结合行为分析、基于规则与分布的启发式方法，以及由 VLM 推理引导的主观语义建模，并通过人机协同验证进行最终优化。基于该数据集，我们首次建立了标准化基准，用于系统性评估个性化 E2EAD 模型。对前沿架构的实证评估表明，融入个性化驾驶偏好可显著提升模型行为与人类示范的一致性。

## 1 引言

随着自动驾驶 (AD) 技术的不断成熟，将这些系统转化为实际产品的关键因素之一是个性化。根据个体用户偏好定制车辆行为对于提升用户体验、建立信任并促进长期采用至关重要 Hasenjäger and Wersing [2017]。传统的模块化系统已广泛探索了个性化策略，能够适应特定的驾驶偏好。然而，这些方法通常依赖于孤立的、场景特定的适应 Tian et al. [2022] 或不切实际的人机协同 (HITL) 仿真 Ke et al. [2024]，严重限制了它们在动态真实环境中的泛化能力。此外，模块化系统的碎片化特性 Zhu et al. [2018], Cui et al. [2024], Kou et al. [2025] 阻碍了其对大规模真实数据的扩展性。由于这些局限性，个性化在端到端自动驾驶 (E2EAD) 中仍基本未被深入探索，其中感知、规划和控制集成在一个统一架构中 Codevilla et al. [2018]。这一差距构成了实现规模化以人为本的自动驾驶的重大障碍。

这一差距尤为紧迫。随着端到端自动驾驶 (E2EAD) 系统能力日益增强，并被部署于多样化的开放世界驾驶环境中，使车辆行为与用户偏好对齐对于提升舒适性、感知安全性以及长期用户接受度至关重要 Speidel et al. [2019], Aledhari et al. [2023]。然而，将个性化整合到端到端范式中带来了独特的挑战。与在狭义定义场景中运行的模块化系统不同，E2EAD 需要

---

\*Corresponding to zaiqing@air.tsinghua.edu.cn.

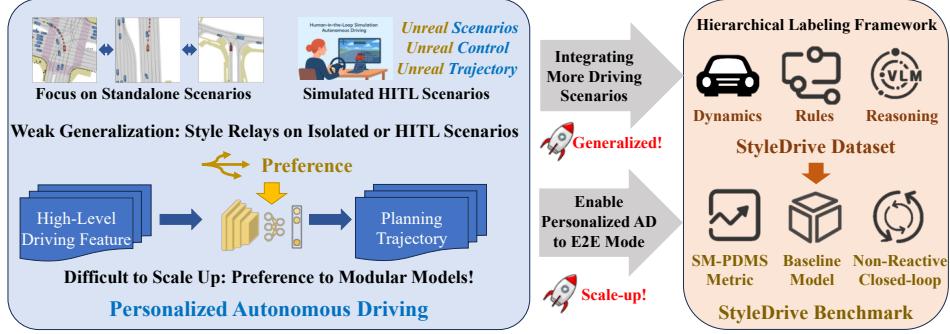


图 1: StyleDrive 的动机与概览。

在广泛复杂的现实场景中实现偏好泛化。满足这一需求需要大规模数据集，这些数据集不仅需涵盖多样的交通状况，还需提供精心设计的驾驶风格标注。

为了填补这一关键空白，我们引入了首个专为个性化端到端自动驾驶（E2EAD）研究设计的大规模真实世界数据集。我们的数据集捕捉了各种驾驶场景下的客观行为模式和主观驾驶偏好。首先从真实道路拓扑中提取静态环境特征，而动态上下文线索则通过微调的视觉语言模型（VLM）推断得出，从而实现丰富的语义场景理解。基于这些特征，我们通过行为分布分析和规则 & 分布驱动的启发式方法生成客观标注。为了融入主观性，我们进一步利用 VLM 结合静态和动态场景语义来标注偏好。该流水线最终通过标签融合机制确保质量和一致性。在此数据集基础上，我们建立了首个用于评估个性化 E2EAD 模型的基准。我们在多种前沿架构上进行了广泛的实验，包括有无偏好条件的情况，结果表明引入个性化显著提升了与人类驾驶行为的一致性。

我们的工作动机与概述如图 1 所示，旨在弥合端到端异常检测（E2EAD）日益增长的动量与异常检测中长期存在的个性化需求之间的差距。总而言之，我们的主要贡献包括：

- 一种新型大规模真实世界数据集，用于个性化端到端自动驾驶，涵盖了各种交通场景下的客观行为和主观驾驶风格偏好标注。
- 一个多阶段标注流水线，通过整合行为特征分析、基于规则和分布的启发式方法、视觉语言模型推理以及人机协同验证，生成高质量且精心设计的偏好标签。
- 个性化端到端行为识别的首个基准，实现了对四种不同先进模型架构在偏好条件下的行为进行标准化、定量比较。
- 全面的实证结果表明，融入用户驾驶偏好能显著提升与人类行为的一致性，凸显了个性化在端到端自动驾驶中的价值。

## 2 相关工作

**个性化自动驾驶** 个性化长期以来被认为是提升用户舒适度、信任度和对 AD 接受度的关键因子 Liao et al. [2024]。在传统的模块化流水线中，已广泛探索了个性化策略，系统可以在独立驾驶场景中适应用户的偏好，例如跟车、汇入匝道和变道行为 Zhao et al. [2022], Li et al. [2023], Liao et al. [2023]。其他早期尝试则在不切实际的人机协同（HITL）仿真中对模型进行个性化 Ke et al. [2024]。然而，这些方法在动态的真实环境中往往泛化能力较差。

大语言模型（LLMs）的最新进展为自动驾驶（AD）中的个性化带来了新可能，能够编码用户意图和偏好以影响下游决策 Cui et al. [2024], Xu et al. [2024], Kou et al. [2025]。尽管潜

表 1：不同驾驶数据集在数据来源、场景覆盖、评估协议、端到端（E2E）支持以及驾驶风格标注方面的对比。**StyleDrive** 是唯一一个结合了真实世界数据、多样化场景、半闭环（Semi-CL）评估、端到端学习能力以及结构化驾驶风格标签的驾驶数据集，适用于个性化自动驾驶。

缩写说明：OL = 开环，CL = 闭环，Semi-CL = 半闭环，HITL = 人机协同，E2E = 端到端驾驶模型支持，Style = 带有风格或偏好标注

Dataset	Reality	Scenarios	CL/OL	E2E	Style
nuScenes Caesar et al. [2020]	Real	City	OL	✓	✗
OpenScene Peng et al. [2023]	Real	City&Rural	OL	✓	✗
Longest6 Chitta et al. [2022]	Sim	City	CL	✓	✗
CARLA Contributors [2024]	Sim	City	CL	✓	✗
MetaDrive Li et al. [2022]	Sim	City	CL	✓	✗
Bench2Drive Jia et al. [2024]	Sim	City	CL	✓	✗
NAVSIM Dauner et al. [2024]	Real	City&Rural	Semi-CL	✓	✗
HITL-RampMerging Li et al. [2023]	HITL	Ramp-Merge	OL	✗	✓
HITL-CarFollowing Zhao et al. [2022]	HITL	Car-Following	OL	✗	✓
HITL-LaneChange Liao et al. [2023]	HITL	Lane-Change	OL	✗	✓
HITL-MultiScene Ke et al. [2024]	HITL	City	OL	✗	✓
UAH Romera et al. [2016]	Real	City&highway	OL	✗	✓
Brain4Cars Jain et al. [2016]	Real	Lane-Change&Merge	OL	✗	✓
PDB Wei et al. [2025]	Real	City	OL	✗	✓
<b>StyleDrive (Ours)</b>	Real	City&Rural	Semi-CL	✓	✓

力巨大，这些方法仍受限于模块化框架，且通常依赖手工设计的特征。MAVERIC Schrum et al. [2024] 是实现端到端个性化驾驶的一项早期重要尝试。然而，在缺乏标准化数据集和基准的情况下，这些方法在可复现性和可扩展性方面面临挑战。尽管取得这些进展，现有研究很少探讨如何以端到端自动驾驶（E2EAD）方式融合用户偏好。一个关键瓶颈在于缺乏大规模、真实世界中带有精心标注的个性化驾驶风格的数据集。

**端到端自动驾驶** 端到端自动驾驶代表了一种有前景的范式，它将原始传感器输入直接映射为驾驶动作或规划轨迹。早期的工作 Codevilla et al. [2018] 展示了 E2EAD 的可行性。在过去的十年中，研究朝着更复杂的架构发展，这些架构结合了时间推理、多模态融合以及基于 Transformer 的方法 Prakash et al. [2021], Jia et al. [2023], Shao et al. [2023]。

尽管取得了这些进展，大多数端到端自动驾驶（E2EAD）模型仍以平均层面的目标进行优化，缺乏适应用户特定偏好的能力。虽然近期的架构在泛化能力和可解释性方面有所提升 Li et al. [2024], Zheng et al. [2024], Jia et al. [2025]，但在捕捉个性化驾驶风格方面仍然存在局限。此外，缺乏专门用于评估个性化的数据集和标准化基准，持续阻碍了该领域的系统性发展。为解决这些局限，我们提出一种学习风格条件化 E2EAD 模型的框架，并建立一个基准来评估其与人类驾驶行为的一致性。

**自动驾驶基准测试** 基准测试是自动驾驶模型开发与评估的基础。典型的自动驾驶数据集和基准如表 1 所示。早期的端到端自动驾驶基准 Caesar et al. [2020], Peng et al. [2023] 采用基于真实世界数据的非交互式开环情景，但无法捕捉行为反馈。近期研究引入了仿真中的闭环情景，如 Longest6 Chitta et al. [2022]、MetaDrive Li et al. [2022]、CARLA 系列 Contributors [2024]，这些方法支持在线策略评估，但完全依赖于仿真场景。半仿真平台

如 NAVSIM Dauner et al. [2024] 通过基于真实场景模拟行为反馈，在仿真程度上取得平衡。然而，现有基准仍侧重于任务性能，忽视用户偏好，无法评估个性化的驾驶行为。

个性化自动驾驶的基准研究催生了两大类数据集：人机协同（HITL）仿真与真实道路驾驶日志。1) HITL 数据集通常在受控场景中收集，例如匝道合并 Li et al. [2023]、跟车 Zhao et al. [2022]、变道 Liao et al. [2023] 以及多种场景 Ke et al. [2024]。尽管这些设置有助于偏好建模，但往往依赖于简化的仿真引擎和精心设计的环境，导致真实世界条件与不切实际的场景之间存在领域差距。2) 真实世界数据集如 UAH-DriveSet Romera et al. [2016]、Brain4Cars Jain et al. [2016] 和 PDB Wei et al. [2025] 提供了与驾驶意图相关的行为标注。这些数据集在理解驾驶员行为和意图建模方面做出了重要贡献。然而，它们通常局限于狭窄的驾驶情境，如高速公路或交叉路口。更重要的是，这些数据集并未为端到端学习进行结构化设计：大多数仅提供高层行为标签，缺乏从感知到控制的连续监督，且均未包含用于比较个性化驾驶策略的标准评估协议。

为弥合端到端自动驾驶（E2EAD）与个性化自动驾驶之间的差距，我们提出了首个面向个性化端到端自动驾驶的基准。该基准基于真实世界数据构建，支持监督学习以及偏好条件策略的半闭环评估，能够实现个性化端到端自动驾驶在多样化场景下的可复现评估。

### 3 StyleDrive 数据集

StyleDrive 数据集是从大规模自动驾驶数据集 OpenScene Peng et al. [2023] 中采样并构建的，包含近 30,000 个标注了风格偏好的驾驶场景。OpenScene 包含来自新加坡和美国多个城市及郊区环境下的超过 16 名驾驶员收集的轨迹数据。这种多样性为在不同场景中标注用户特定倾向提供了丰富的基础（如图 4 所示）。除了原始的 OpenScene 数据外，我们还引入了一个统一的框架，用于建模和标注个性化的驾驶偏好。

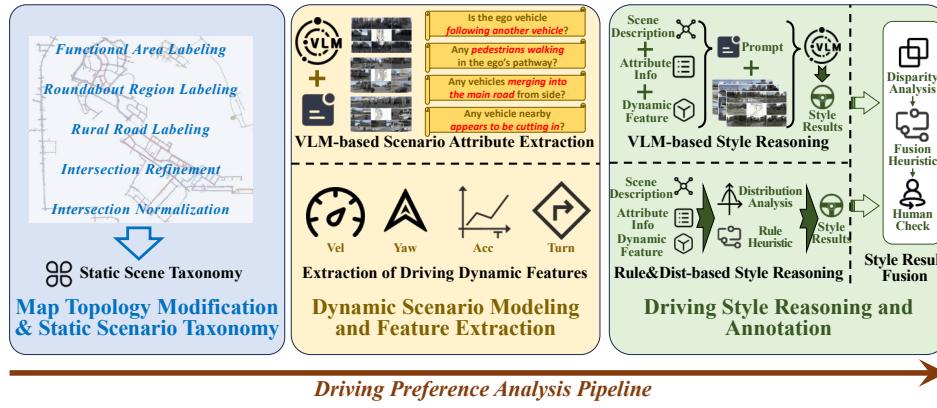


图 2: 驾驶偏好建模与标注框架

#### 3.1 驾驶偏好建模与标注框架

**框架概述。** 为了实现可靠且可解释的驾驶风格分析，我们构建了一个分层建模与标注框架，如图 2 所示。我们从真实道路拓扑中提取静态环境特征，并从驾驶日志中提取动态运动特征，同时利用微调后的视觉语言模型（VLM）推断动态上下文线索，从而实现一致且细粒度的场景构建。基于这些构建的场景特征，我们通过行为分布分析和基于规则的启发式方法推导出客观偏好标注。为捕捉驾驶风格固有的主观性，我们进一步利用 VLM 联合建模场景语

义与驾驶员行为，生成主观标注。最终的高质量标签通过人机协同验证过程获得，综合了上述两种视角。

**拓扑驱动的静态场景分类法** 为了便于对驾驶行为进行结构化分析，我们首先基于高精地图(HD)的拓扑结构，将每个驾驶片段分类为粗粒度的交通场景类型。这种分类为后续的场景建模提供了物理上合理且语义可解释的基础。具体而言，我们首先在原始 nuPlan HD 地图的基础上丰富拓扑结构(详细信息见附录第 3 节)。随后，我们将每个片段数据与详细的地图元素(如车道几何、停车线、人行横道和交叉口布局)对齐，将其归入十一类主要交通场景类型之一。每种类型捕捉了道路环境中的静态约束和导航特征，作为解释下游驾驶行为的结构先验。完整的类型列表如图 3 左侧所示。

**基于视觉-语言模型的动态语义精炼** 为了丰富交通场景分类中的动态、上下文敏感信息，我们采用微调后的视觉-语言模型(VLM)从驾驶视频中提取高层次语义线索。由于通用的 VLM 缺乏面向自动驾驶(AD)任务的特定感知和推理能力，我们通过轻量级微调方法，利用 LingoQA 数据集 Marcu et al. [2024] 对 Video-LLaMA3 模型 Zhang et al. [2025] 进行适配——该数据集是一个用于道路语义推理的多模态数据集(更多细节见附录第 5 节)。

针对每种交通场景类型，我们设计了与关键驾驶事件相关的定制化提示。这些提示包括是否在同车道存在前车、自车是否正在合并，或行人是否可见于人行横道区域等问题。随后，将模型的响应解析为结构化的语义属性，例如前车存在性、合并行为、行人参与情况以及转向意图。这一动态语义层为静态拓扑结构增添了具有交互感知能力且时间上精准的线索，从而通过基于规则和分布的方法以及基于视觉语言模型(VLM)的推理，增强下游偏好建模。

**基于规则与分布的启发式方法的目标偏好标注** 在丰富场景上下文的基础上，我们利用一组可解释、基于物理原理的启发式规则，生成目标驾驶风格标注，这些规则由运动动力学和语义先验指导。我们提取了一系列与行为相关的物理自车运动特征，如速度、加速度、偏航率变化以及与周围智能体的距离。基于这些自车运动特征、结构化的场景语义及静态场景类型，我们分析特征分布，并据此定义出基于聚合驾驶统计量校准的场景特定规则(更多细节见补充材料第 4 节)。例如：

- 低速行驶和在交叉路口留有较大的安全余量，反映出保守的驾驶倾向；
- 突然变道且后方跟车距离过小，表明具有攻击性行为；
- 中速跟驰与稳定车道保持属于正常类别。

基于群体层面的行为分布并经过进一步的专家验证，这些启发式方法为客观风格标签提供了明确且稳健的基础。

**基于视觉语言模型推理的主观偏好标注** 为了补充基于规则和分布的方法，我们利用微调后的 Video-LLama3 的上下文推理能力，生成反映人类对驾驶风格类似理解的主观标注。给定驾驶视频、结构化的场景语义以及相应的提取的自车运动特征，该模型被提示回答诸如行为相关的问题：

- “自动驾驶车辆在行人移动的情况下表现得谨慎吗？”
- 车辆是主动合并还是让行？

这些响应捕捉了超越固定启发式方法表现力的高层次意图和交互线索。多模态注意力使视觉语言模型能够建模细微的行为模式，尤其是在边界情况或语义复杂的场景中。

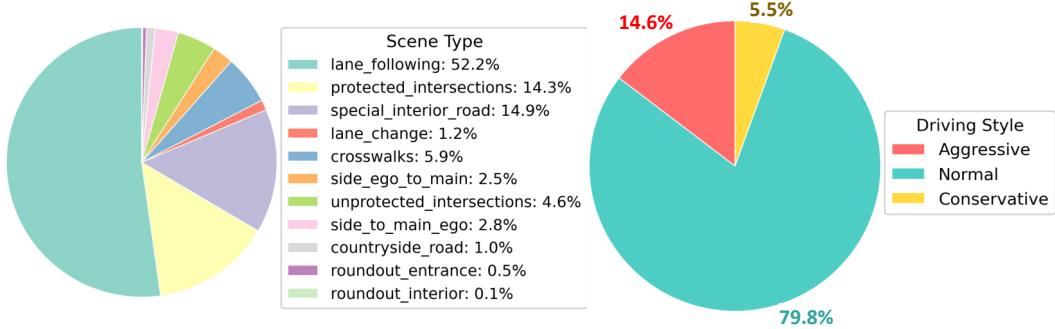


图 3: 数据集统计量与分布分析。

**多源融合与人机协同验证** 在最终确定标注协议之前，我们进行人机协同分析，以评估基于规则 & 分布与基于 VLM 的标签之间的一致性和发散性。人工检查揭示了以下模式：

- 激进驾驶行为通常会被两个来源持续检测到。即使出现分歧，每个来源也经常捕捉到另一个遗漏的有效信号。这种互补行为表明，激进倾向与宽松的合并策略非常契合。
- 相比之下，保守风格和正常风格在低速或模糊的交互中更容易被视觉语言模型混淆。这一观察促使采用更严格的准则来确定保守性分配。

这些观察结果促使我们提出一种风险感知的融合策略：1) 若基于规则或基于视觉语言模型 (VLM) 的推理将某片段标记为激进，则将其标注为激进；2) 若两种来源均认为该片段反映保守行为，则标记为保守；3) 在其他情况下，驾驶风格标记为正常。该策略通过在潜在激进行为上保持宽松、在保守判定上保持严格，强调了一致性。同时，该策略确保最终标签兼具可解释性与鲁棒性。此外，最终的标注还会通过针对性的人工审查对边缘情况进一步验证，以保障标签的可靠性。

### 3.2 数据集统计、风格分布与可视化

为了对 StyleDrive 数据集提供全局概览，我们展示了场景构成和标注驾驶偏好方面的关键统计量。如图 3 所示，我们使用两个互补的饼图，可视化了静态/动态场景类型与行为风格之间的分布情况。

**场景构图。** 左侧图表展示了交通场景类型的分布情况。车道保持和交叉路口场景在数据集中占主导地位，反映了它们在实际驾驶中的普遍性。包含丰富上下文的类型，如合并、变道和行人交互，增加了场景的多样性。

**驾驶风格分布。** 右图展示了驾驶偏好标注结果。正常行为占多数，而激进和保守风格虽然较少，但具有足够的代表性。这种分布反映了典型的驾驶模式，有利于平衡学习，尤其有助于边缘情况的识别。更多数据集统计信息见附录第 2 节。

**驾驶风格可视化。** 图 4 突出了不同驾驶风格的分布。值得注意的是，即使在相似的驾驶条件下，驾驶员的行为偏好仍存在显著差异。

## 4 StyleDrive 基准

为推动个性化端到端自动驾驶 (E2EAD) 的发展与评估，我们引入了 StyleDrive 基准，这是一个基于非反应式仿真的评估框架，用于在真实交通场景中评估驾驶偏好与性能。该基准旨

在检验自动驾驶智能体能否生成符合目标驾驶风格的行为，同时确保安全性和社会合规性。基于 StyleDrive 数据集丰富的场景和结构化标注，该基准定义了一个标准化测试平台，包含四个组成部分：仿真环境、提出的 SM-PDMS 指标、基准模型以及包含性能分析的基准结果。

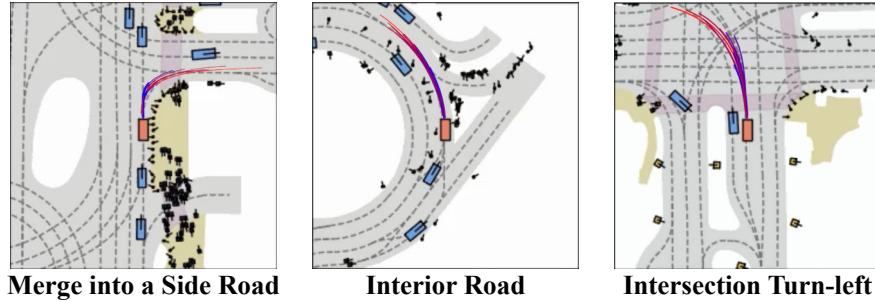


图 4：三种典型场景下驾驶风格分布的可视化。每种情况均选取相似的局部场景，且不包含行人或前车，以确保风格差异主要源于驾驶员自身的行为偏好。红色轨迹表示激进风格，蓝色轨迹表示保守风格。更多示例见附录第 2 节。

**仿真环境** 我们的基准基于轻量级仿真器 NavSim Dauner et al. [2024] 构建，该仿真器强调非反应式行为仿真，并建立在真实世界交通场景基础上。在我们的适配中，重放了 StyleDrive 的场景，风格条件化的端到端自动驾驶模型在此环境中学习策略。

#### 4.1 评估指标：风格调制的 PDMS

为了评估一个模型是否不仅确保安全性和可行性，还与期望的驾驶风格对齐，我们提出了风格调制的预测性驾驶员模型得分 (SM-PDMS)，这是在 NavSim Dauner et al. [2024] 中提出的预测性驾驶员模型得分 (PDMS) 基础上的扩展。SM-PDMS 通过引入行为对齐分量，增强了原始的 PDMS，该分量量化了策略符合指定风格偏好程度。与驾驶风格无关的交通安全与道路保持相关子指标保持不变，因为它们被认为是不变的。相反，驾驶风格主要体现在运动动态上，例如跟车距离、速度和角速度，这些又影响到对风格敏感的子指标，包括舒适性 (Comf.)、自车进度 (EP) 和碰撞时间 (TTC)。

在不同驾驶风格下对风格敏感的子指标采用相同的度量配置，对于评估风格条件策略来说并非最优方案，因为具有不同偏好的用户会以不一致的方式定义“更优”的驾驶行为。为解决这一问题，我们通过标注的驾驶风格来调节与风格相关的子指标。具体而言：

- “EP”：ego 进展目标根据目标巡航速度和理想的跟车距离进行校准；
- “Comf.”：舒适相关阈值会随之调节，以反映对物理干扰的不同敏感度；
- “TTC”：TTC 可接受值域根据不同风格间的异质性风险容差进行调整。

这些修改的更多细节见补充材料第 1 节。它们确保了 SM-PDMS 能够对安全性和风格一致性进行系统性评估。

#### 4.2 基准方法

为便于标准化比较，我们实现了四种具有代表性的风格条件基线，涵盖不同模型复杂度和范式，具体如下。

表 2: StyleDrive 基准测试主要结果。风格条件控制提升了行为一致性，各模型系列的 SM-PDMS 得分均有所提高。消融实验结果（底部）进一步证实了风格条件控制的有效性和可学习性。

Models	NC ↑	DAC ↑	Style-Modulated Submetrics			SM-PDMS ↑
			TTC ↑	Comf. ↑	EP ↑	
AD-MLP Zhai et al. [2023]	92.63	77.68	83.83	99.75	78.01	63.72
TransFuser Chitta et al. [2022]	96.74	88.43	91.08	99.65	84.39	78.12
WoTE Li et al. [2025]	97.29	92.39	92.53	99.13	76.31	79.56
DiffusionDrive Liao et al. [2025]	96.66	91.45	90.63	99.73	80.39	79.33
AD-MLP-Style	92.38	73.23	83.14	<b>99.90</b>	78.55	60.02
TransFuser-Style	97.23	90.36	92.61	99.73	<b>84.95</b>	81.09
WoTE-Style	<b>97.58</b>	<b>93.44</b>	<b>93.70</b>	99.26	77.38	<b>81.38</b>
DiffusionDrive-Style	<b>97.81</b>	<b>93.45</b>	<b>92.81</b>	<b>99.85</b>	<b>84.84</b>	<b>84.10</b>
- DiffusionDrive-Style-A	97.38	93.20	92.01	99.62	84.01	83.04
- DiffusionDrive-Style-N	97.66	93.32	92.16	99.83	84.21	83.52
- DiffusionDrive-Style-C	98.23	93.59	94.98	99.87	81.36	83.90

- **AD-MLP-Style**: 在 AD-MLP 基准 Zhai et al. [2023] 的基础上，将独热编码的驾驶风格向量与自身状态连结，组合后的输入通过多层感知机进行风格感知的轨迹回归。
- **TransFuser-Style**: 基于 TransFuser Chitta et al. [2022]，该方法将图像和激光雷达特征用于规划。将独热风格向量与轨迹查询连结，通过多层感知机融合以恢复维度，然后输入到轨迹预测头。
- **DiffusionDrive-Style**: 通过在轨迹头中注入一个独热风格向量来修改 DiffusionDrive Liao et al. [2025]。该向量与智能体特征连结，经由一个融合多层感知机 (MLP) 融合，随后接一个回归多层感知机。此块运行两次以实现级联优化。
- **WoTE-风格**: 采用 BEV World 模型 Li et al. [2025]，该模型预测未来的 BEV 状态。通过拼接和 MLP 融合的方式将驾驶风格注入偏移预测头，策略与 DiffusionDrive-Style 相同。

训练细节见附录第 5 节。

### 4.3 主要结果分析

**风格条件化改善行为一致性。** 表 2 的前两节展示了所提出的基准模型在 StyleDrive 基准上的定量评估结果。在三种模型族——TransFuser、WoTE 和 DiffusionDrive——中，风格条件化变体的 SM-PDMS 得分高于其原始版本，明确证明了风格条件化的有效性。相比之下，AD-MLP-Style 变体在 SM-PDMS 上略低于其原始版本。

总体而言，TransFuser、WoTE 和 DiffusionDrive 在风格敏感指标（如 TTC、Comf. 和 EP）上的改进，证实了在规划中融入风格信息的有效性。风格条件模型在舒适度和 EP 指标上持续取得提升，也进一步为我们的驾驶风格标注的合理性提供了有力证据。从个体表现来看，DiffusionDrive-Style 表现最强，在大多数指标上均获得最高得分；WoTE-Style 与 TransFuser-Style 紧随其后，且显著优于原始的 DiffusionDrive 模型，进一步凸显了风格条件化带来的优势。

AD-MLP 的发散趋势可归因于其简单性：由于缺乏感知能力，该模型无法有效利用风格信息。尽管 EP 表现出轻微提升，表明意图保留略有改善，但 DAC 的下降最终导致整体得分降低。

**固定风格条件的消融实验。** 表 2 的最后一部分报告了一项消融实验，其中通过覆盖标注的风格，而在测试时强制执行固定风格条件来评估 DiffusionDrive-Style 模型。例如，DiffusionDrive-Style-A 对所有场景均采用激进风格条件，而不考虑真实情况下的条件。结果进一步证实了我们风格条件的有效性和可学习性：当条件风格从激进转变为保守时，NC 和 DAC 明显提升。TTC 和 Comf. 也有所增加，因为 SM-PDMS 指标不会对过于安全或平滑的行为进行惩罚。由于正常风格在数据集中占主导地位，EP 在该风格下达到峰值。此外，固定风格条件的表现不及真实风格条件，进一步验证了风格标签的可靠性。

**与人类示范的接近程度。** 为了进一步评估风格条件化模型的行为保真度，我们采用与人类驾驶示范的 L2 轨迹误差进行开环评估。如表 3 所示，风格感知变体在所有预测时域上均表现出更低的预测误差，其中 DiffusionDrive-Style 表现最佳。这些结果表明，风格条件化不仅增强了风格表现力，还提高了与人类行为的直接一致性。

表 3: L2 开环评估结果。在风格条件约束下，模型的 L2 轨迹误差低于原始模型，表明在偏好感知条件下，其与人类驾驶行为的一致性得到提升。

Models	L2 (2s) ↓	L2 (3s) ↓	L2 (4s) ↓	L2 (Avg) ↓
WoTE Li et al. [2025]	0.733	1.434	2.349	1.506
AD-MLP Zhai et al. [2023]	0.503	1.262	2.383	1.382
TransFuser Chitta et al. [2022]	0.431	0.963	1.701	1.032
DiffusionDrive Liao et al. [2025]	0.471	1.086	1.945	1.167
WoTE-Style	0.673	1.340	2.223	1.412
AD-MLP-Style	0.510	1.230	2.321	1.354
TransFuser-Style	0.424	0.937	1.656	1.006
DiffusionDrive-Style	<b>0.417</b>	<b>0.940</b>	<b>1.646</b>	<b>1.001</b>

**PDMS 与 SM-PDMS 的敏感性分析** 表 4 展示了原始 PDMS 与 SM-PDMS 架构在三个有效风格条件模型中，关于风格敏感子指标及最终得分的标准差和值域的对比分析。在不同模型中，SM-PDMS 在最终指标得分以及如 EP 和 Comf 等风格敏感子指标上表现出更高的标准差和值域，表明其对驾驶风格的敏感性得到了提升。

表 4: 在 PDMS 和 SM-PDMS 下，有效风格条件模型评估指标的标准差 (std.) 和值域。SM-PDMS 在保持整体一致性的同时，增强了对特定风格行为的敏感性；而 PDMS 指标即使在舒适度子指标无变化的情况下，仍表现出有限的区分能力。

Attribute	Original PDMS		SM-PDMS	
	std.	range	std.	range
EP	1.657	3.28	<b>4.339</b>	<b>7.57</b>
TTC	0.643	1.16	0.575	1.08
Comf.	0.000	0.00	<b>0.312</b>	<b>0.59</b>
Scores	1.614	2.48	<b>1.660</b>	<b>3.01</b>

**风格影响的定性案例研究。** 为了进一步说明风格条件对行为的影响，图 5 展示了在相同场景下，我们的 DiffusionDrive-Style 模型在激进、保守和正常风格输入下的不同轨迹预测。在各类场景中，模型的轨迹选择呈现出明显差异。这些可视化结果证实，同一策略网络在不同风格向量的条件下，能够生成与人类风格变化相一致的行为多样化输出。这证明了风格条件机制所带来的可控性和表现力。

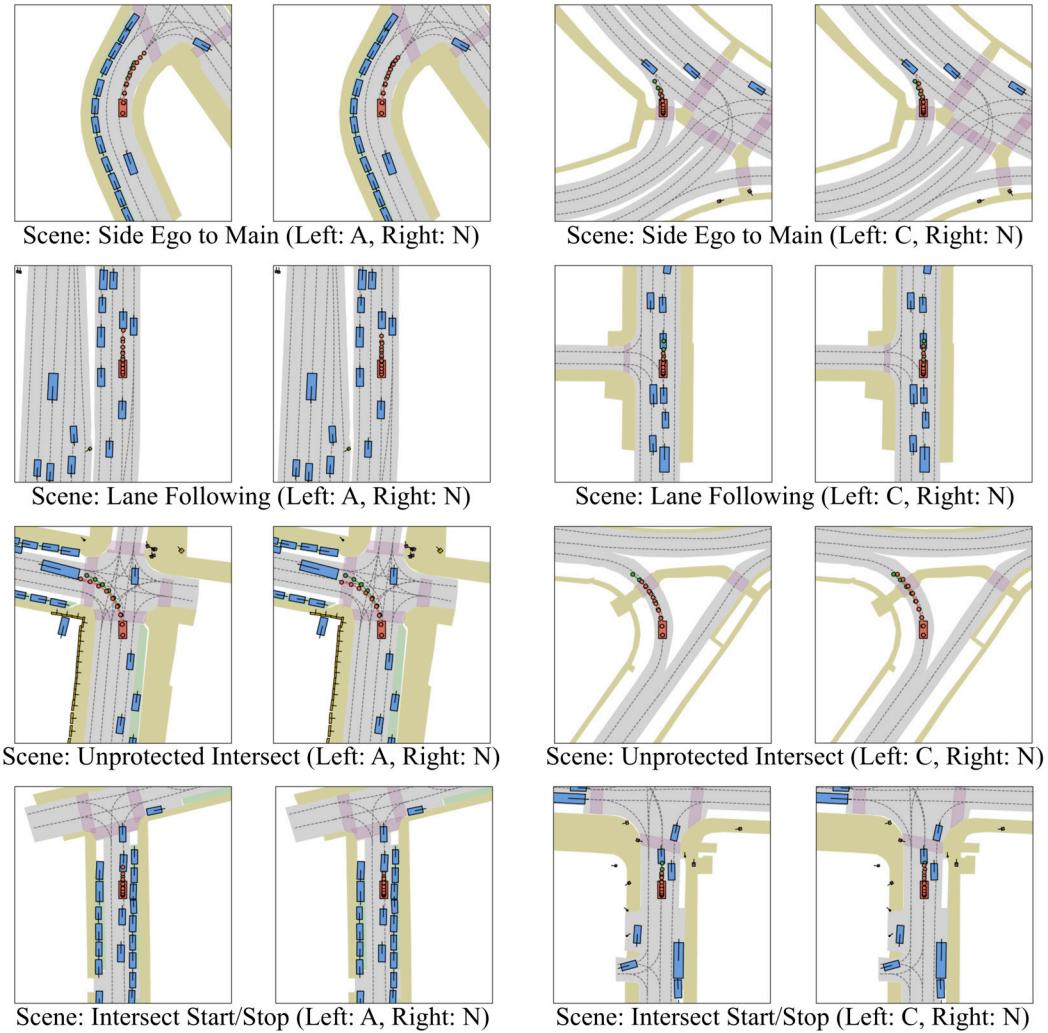


图 5: 在相同场景下，不同驾驶风格条件下 DiffusionDrive-风格预测的定性示意图。左图：激进 (A) 与正常 (N)；右图：保守 (C) 与正常 (N)。红色线条表示模型在给定风格条件下的预测轨迹，绿色线条表示人类真实轨迹。随着风格变化，明显的行为差异显现，体现了模型根据驾驶偏好调整输出的能力。

## 5 结论

本文介绍了 StyleDrive，这是一个新颖的大规模数据集和基准，旨在推动个性化端到端自动驾驶 (E2EAD) 的发展。通过系统性地整合地图拓扑分析、来自视觉-语言模型的细粒度语义上下文，以及结合规则 & 分布启发式与主观 VLM 推理的混合标注流水线，我们建立了一个丰富且可解释的驾驶风格标注基础。该数据集涵盖了广泛的真实交通场景，并用精心设计的风格偏好标签进行标注。为了促进个性化 E2EAD 的开发与评估，我们进一步提出

了 StyleDrive 基准，这是一个非反应式的仿真评估平台。该基准的核心是 Style-Modulated PDMS 指标，该指标在传统安全性和可行性评估的基础上，增加了针对目标驾驶员偏好的风格一致性度量。在多种模型范式上的大量实验表明，风格条件化能够有效提升行为一致性，同时保持核心驾驶能力。

**展望。** **粗粒度到细粒度的标签：**当前风格标注采用三级层次结构，但尝试更细粒度的标注往往导致模糊或重叠。进一步增强场景理解/建模能力以及使用更大规模的数据集可能有助于解决此类模糊性问题。**模型：**除了基准的基线方法外，未来工作应探索场景上下文与驾驶风格偏好之间的联合建模。**应用：**在真实场景中从用户（长期）画像推断风格仍是一个开放性挑战，对商业部署具有重要意义。

## 参考文献

- Mohammed Aledhari, Mohamed Rahouti, Junaid Qadir, Basheer Qolomany, Mohsen Guizani, and Ala Al-Fuqaha. Motion comfort optimization for autonomous vehicles: Concepts, methods, and techniques. *IEEE Internet of Things Journal*, 11(1):378–402, 2023.
- Holger Caesar, Varun Bankiti, Alex H Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuscenes: A multimodal dataset for autonomous driving. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 11621–11631, 2020.
- Kashyap Chitta, Aditya Prakash, Bernhard Jaeger, Zehao Yu, Katrin Renz, and Andreas Geiger. Transfuser: Imitation with transformer-based sensor fusion for autonomous driving. *IEEE transactions on pattern analysis and machine intelligence*, 45(11):12878–12895, 2022.
- Felipe Codevilla, Matthias Müller, Antonio López, Vladlen Koltun, and Alexey Dosovitskiy. End-to-end driving via conditional imitation learning. In *2018 IEEE international conference on robotics and automation (ICRA)*, pages 4693–4700. IEEE, 2018.
- Contributors. Carla autonomous driving leaderboard, 2024. URL <https://leaderboard.carla.org/>.
- Can Cui, Zichong Yang, Yupeng Zhou, Yunsheng Ma, Juanwu Lu, Lingxi Li, Yaobin Chen, Jitesh Panchal, and Ziran Wang. Personalized autonomous driving with large language models: Field experiments. In *2024 IEEE 27th International Conference on Intelligent Transportation Systems (ITSC)*, pages 20–27. IEEE, 2024.
- Daniel Dauner, Marcel Hallgarten, Andreas Geiger, and Kashyap Chitta. Parting with misconceptions about learning-based vehicle motion planning. In *Conference on Robot Learning*, pages 1268–1281. PMLR, 2023.
- Daniel Dauner, Marcel Hallgarten, Tianyu Li, Xinshuo Weng, Zhiyu Huang, Zetong Yang, Hongyang Li, Igor Gilitschenski, Boris Ivanovic, Marco Pavone, et al. Navsim: Data-driven non-reactive autonomous vehicle simulation and benchmarking. *Advances in Neural Information Processing Systems*, 37:28706–28719, 2024.

Martina Hasenjäger and Heiko Wersing. Personalization in advanced driver assistance systems and autonomous vehicles: A review. In *2017 ieee 20th international conference on intelligent transportation systems (itsc)*, pages 1–7. IEEE, 2017.

Ashesh Jain, Hema S Koppula, Shane Soh, Bharad Raghavan, Avi Singh, and Ashutosh Saxena. Brain4cars: Car that knows before you do via sensory-fusion deep learning architecture. *arXiv preprint arXiv:1601.00740*, 2016.

Xiaosong Jia, Penghao Wu, Li Chen, Jiangwei Xie, Conghui He, Junchi Yan, and Hongyang Li. Think twice before driving: Towards scalable decoders for end-to-end autonomous driving. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21983–21994, 2023.

Xiaosong Jia, Zhenjie Yang, Qifeng Li, Zhiyuan Zhang, and Junchi Yan. Bench2drive: Towards multi-ability benchmarking of closed-loop end-to-end autonomous driving. *arXiv preprint arXiv:2406.03877*, 2024.

Xiaosong Jia, Junqi You, Zhiyuan Zhang, and Junchi Yan. Drivetransformer: Unified transformer for scalable end-to-end autonomous driving. *arXiv preprint arXiv:2503.07656*, 2025.

Zehong Ke, Yanbo Jiang, Yuning Wang, Hao Cheng, Jinhao Li, and Jianqiang Wang. D2e: An autonomous decision-making dataset involving driver states and human evaluation of driving behavior. In *2024 IEEE 27th International Conference on Intelligent Transportation Systems (ITSC)*, pages 2294–2301. IEEE, 2024.

Genghua Kou, Fan Jia, Weixin Mao, Yingfei Liu, Yucheng Zhao, Ziheng Zhang, Osamu Yoshie, Tiancai Wang, Ying Li, and Xiangyu Zhang. Padriver: Towards personalized autonomous driving. *arXiv preprint arXiv:2505.05240*, 2025.

Quanyi Li, Zhenghao Peng, Lan Feng, Qihang Zhang, Zhenghai Xue, and Bolei Zhou. Metadrive: Composing diverse driving scenarios for generalizable reinforcement learning. *IEEE transactions on pattern analysis and machine intelligence*, 45(3):3461–3475, 2022.

Siyan Li, Chuheng Wei, Guoyuan Wu, Matthew J Barth, Amr Abdelraouf, Rohit Gupta, and Kyungtae Han. Personalized trajectory prediction for driving behavior modeling in ramp-merging scenarios. In *2023 Seventh IEEE International Conference on Robotic Computing (IRC)*, pages 1–4. IEEE, 2023.

Yingyan Li, Lue Fan, Jiawei He, Yuqi Wang, Yuntao Chen, Zhaoxiang Zhang, and Tieniu Tan. Enhancing end-to-end autonomous driving with latent world model. *arXiv preprint arXiv:2406.08481*, 2024.

Yingyan Li, Yuqi Wang, Yang Liu, Jiawei He, Lue Fan, and Zhaoxiang Zhang. End-to-end driving with online trajectory evaluation via bev world model. *arXiv preprint arXiv:2504.01941*, 2025.

Bencheng Liao, Shaoyu Chen, Haoran Yin, Bo Jiang, Cheng Wang, Sixu Yan, Xinbang Zhang, Xiangyu Li, Ying Zhang, Qian Zhang, et al. Diffusiondrive: Truncated diffusion model for end-to-end autonomous driving. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2025.

Xishun Liao, Xuanpeng Zhao, Ziran Wang, Zhouqiao Zhao, Kyungtae Han, Rohit Gupta, Matthew J Barth, and Guoyuan Wu. Driver digital twin for online prediction of personalized lane-change behavior. *IEEE Internet of Things Journal*, 10(15):13235–13246, 2023.

Xishun Liao, Zhouqiao Zhao, Matthew J Barth, Amr Abdelraouf, Rohit Gupta, Kyungtae Han, Jiaqi Ma, and Guoyuan Wu. A review of personalization in driving behavior: Dataset, modeling, and validation. *IEEE Transactions on Intelligent Vehicles*, 2024.

Ana-Maria Marcu, Long Chen, Jan Hünermann, Alice Karnsund, Benoit Hanotte, Prajwal Chidananda, Saurabh Nair, Vijay Badrinarayanan, Alex Kendall, Jamie Shotton, et al. Lingoqa: Visual question answering for autonomous driving. In *European Conference on Computer Vision*, pages 252–269. Springer, 2024.

Songyou Peng, Kyle Genova, Chiyu Jiang, Andrea Tagliasacchi, Marc Pollefeys, Thomas Funkhouser, et al. Openscene: 3d scene understanding with open vocabularies. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 815–824, 2023.

Aditya Prakash, Kashyap Chitta, and Andreas Geiger. Multi-modal fusion transformer for end-to-end autonomous driving. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 7077–7087, 2021.

Eduardo Romera, Luis M Bergasa, and Roberto Arroyo. Need data for driver behaviour analysis? presenting the public uah-driveset. In *2016 IEEE 19th international conference on intelligent transportation systems (ITSC)*, pages 387–392. IEEE, 2016.

Mariah L Schrum, Emily Sumner, Matthew C Gombolay, and Andrew Best. Maveric: A data-driven approach to personalized autonomous driving. *IEEE Transactions on Robotics*, 40:1952–1965, 2024.

Hao Shao, Letian Wang, Ruobing Chen, Hongsheng Li, and Yu Liu. Safety-enhanced autonomous driving using interpretable sensor fusion transformer. In *Conference on Robot Learning*, pages 726–737. PMLR, 2023.

Oliver Speidel, Maximilian Graf, Thanh Phan-Huu, and Klaus Dietmayer. Towards courteous behavior and trajectory planning for automated driving. In *2019 IEEE Intelligent Transportation Systems Conference (ITSC)*, pages 3142–3148. IEEE, 2019.

Hanqing Tian, Chao Wei, Chaoyang Jiang, Zirui Li, and Jibin Hu. Personalized lane change planning and control by imitation learning from drivers. *IEEE Transactions on Industrial Electronics*, 70(4):3995–4006, 2022.

Chuheng Wei, Ziye Qin, Siyan Li, Ziyan Zhang, Xuanpeng Zhao, Amr Abdelraouf, Rohit Gupta, Kyungtae Han, Matthew J Barth, and Guoyuan Wu. Pdb: Not all drivers are the same—a personalized dataset for understanding driving behavior. *arXiv preprint arXiv:2503.06477*, 2025.

Zhenhua Xu, Yujia Zhang, Enze Xie, Zhen Zhao, Yong Guo, Kwan-Yee K Wong, Zhenguo Li, and Hengshuang Zhao. Drivegpt4: Interpretable end-to-end autonomous driving via large language model. *IEEE Robotics and Automation Letters*, 2024.

Jiang-Tian Zhai, Ze Feng, Jinhao Du, Yongqiang Mao, Jiang-Jiang Liu, Zichang Tan, Yifu Zhang, Xiaoqing Ye, and Jingdong Wang. Rethinking the open-loop evaluation of end-to-end autonomous driving in nuscenes. *arXiv preprint arXiv:2305.10430*, 2023.

Boqiang Zhang, Kehan Li, Zesen Cheng, Zhiqiang Hu, Yuqian Yuan, Guanzheng Chen, Sicong Leng, Yuming Jiang, Hang Zhang, Xin Li, et al. Videollama 3: Frontier multimodal foundation models for image and video understanding. *arXiv preprint arXiv:2501.13106*, 2025.

Zhouqiao Zhao, Ziran Wang, Kyungtae Han, Rohit Gupta, Prashant Tiwari, Guoyuan Wu, and Matthew J Barth. Personalized car following for autonomous driving with inverse reinforcement learning. In *2022 International Conference on Robotics and Automation (ICRA)*, pages 2891–2897. IEEE, 2022.

Wenzhao Zheng, Ruiqi Song, Xianda Guo, Chenming Zhang, and Long Chen. Genad: Generative end-to-end autonomous driving. In *European Conference on Computer Vision*, pages 87–104. Springer, 2024.

Bing Zhu, Shude Yan, Jian Zhao, and Weiwen Deng. Personalized lane-change assistance system with driver behavior identification. *IEEE Transactions on Vehicular Technology*, 67(11):10293–10306, 2018.

## 补充材料概述

本附录提供了与 StyleDrive 数据集和基准相关的额外实验及详细信息。具体包括：

- 第 1 节提供了关于风格感知评估指标设计的更多细节。
- 第 2 节展示了更多风格标注结果的示例，并说明了额外的数据集统计量。
- 第 3 节描述了针对地图拓扑的修改，旨在支持更多样化的静态驾驶场景。
- 第 4 节解释了使用规则 & 分布驱动的启发式方法进行偏好标注的过程，以及相关分析。
- 第 5 节讨论了用于驾驶场景理解的基准方法训练和视觉语言模型微调的细节。

### 1 风格感知度量设计的详细信息

本节详细解释了风格调制的 PDM 得分 (SM-PDMS) 如何调整关键子指标：舒适度、自我进度和碰撞时间，针对标注的驾驶风格：激进、正常和保守。

这些调整确保评估不仅考虑安全性和可行性，还兼顾特定风格的驾驶偏好。以下是用于每个子得分的精确配置：

#### 1.1 舒适度 (Comf.)

**PDMS 中原始舒适度度量的局限性** 原始的 PDMS 框架 Dauner et al. [2024] 通过惩罚表现出过度加速度和加速度的轨迹来评估舒适性，其依赖于从经验研究或模拟器动力学得出的固定阈值。尽管该方法能有效避免物理上不稳定的运动，但对所有驾驶风格施加统一标准，忽视了不同驾驶员类型在舒适性感知上的显著差异。例如，保守型驾驶员可能认为突然的动作是不舒适的，而激进型驾驶员则可能认为是可以接受的。通过在任何情境或偏好下都强制使用静态阈值，该度量忽略了驾驶风格的细微差别，且可能错误地惩罚那些有意果断但仍在可接受人体容差范围内的行为。

**风格感知的舒适阈值在 SM-PDMS 中的应用** 为了更好地考虑个体驾驶风格的偏好，我们在 SM-PDMS 中引入了针对舒适性指标的风格感知阈值。具体而言，我们根据指定的驾驶风格类别对基准加速度和急动度阈值进行调节：

- **保守型**：对动态变化的容差较低。基准阈值收紧 20%，导致对突然加速和加速度的惩罚更严格。
- **激进**：对动态机动的容差更高。阈值放宽 20%，允许更主动的行为而不会受到惩罚。
- **正常**：保留原始默认阈值，提供中性基准。

这些风格调整后的阈值决定了特定动作是否被视为不舒适而受到惩罚，或被接受为流畅，从而将舒适度评估与主观的人类偏好保持一致。这种重新表述使舒适度度量不仅反映物理可行性，还体现风格意图，确保智能体在不同驾驶风格下都能得到公平评估。

#### 1.2 自我进步 (EP)

**PDMS 中原始 EP 度量的局限性** 在原始的 PDMS 框架 Dauner et al. [2024] 中，自行车进度 (Ego Progress, EP) 度量指标衡量的是自行车在其预测轨迹上前进的距离。这是通过将评估智能体的累计进度与一个固定规则基线智能体 (PDM) Dauner et al. [2023] 的进度进行比较来实现的。如果该智能体行驶的距离小于 PDM，则得分为其进度与 PDM 进度的比

值；否则，得分为满分 1。尽管这种方法在基本层面上捕捉了任务完成情况，但引入了若干局限性。首先，它将进度评估简化为对智能体是否优于单一规则基线的二元判断。其次，它未提供“偏差程度”是否可接受或风格一致性方面的概念——只要智能体在距离上超过 PDM，即使加速过于激进或过度犹豫也不会受到惩罚。因此，原始的 EP 度量缺乏对人类驾驶意图的敏感性，也无法区分风格不一致的轨迹。

**风格感知重构的 SM-PDMS 中的 EP** 为了克服这些局限性，我们在 SM-PDMS 中提出了一种基于人类参考和风格感知的 EP 指标重构方法。与对比评估智能体进展与基于规则的系统不同，我们直接将其与人类示范者的轨迹进行比较，从而同时捕捉运动的幅度和风格。令  $EP_{agent}$  表示智能体在 4 秒时间窗内累计行进的距离， $EP_{target}$  表示人类示范在相同时段内覆盖的距离。最终的 EP 得分定义为：

$$S_{EP} = \max \left( 1 - \alpha \times \left( \frac{EP_{agent} - EP_{target}}{Ref} \right)^2, 0 \right) \quad (1)$$

其中  $\alpha$  为敏感性缩放因子（经验设定为 1.2）， $Ref$  为容差参数，用于调节可接受偏差的程度。根据人类轨迹长度分配  $Ref$ ：若  $EP_{target} < 10$  则为 3，若  $10 \leq EP_{target} < 24$  则为 5，若  $24 \leq EP_{target} < 40$  则为 6，否则为 7。该公式同时惩罚过度前进和前进不足，鼓励智能体不仅匹配目标达成行为，还匹配人类驾驶的渐进特征，如决断性、犹豫或果断性。通过这种方式，使该度量更贴近 SM-PDMS 的风格保真度目标。

### 1.3 碰撞时间 (TTC)

**PDMS 中原始 TTC 指标的局限性** 在原始实现中，碰撞时间 (TTC) 指标采用二值风险分配方案。具体而言，一旦在任何未来的时间步中检测到本车与另一交通参与者之间存在潜在的几何交叉，且满足某些语义条件（如交互智能体位于本车前方，或本车处于复杂或不可行驶区域，例如交叉路口或多车道区域），则该轨迹的 TTC 得分即被赋予 0 分；否则，TTC 得分保持其默认值 1 分。

该方法将 TTC 计算有效简化为“碰撞风险”与“无风险”的二分类问题，但未考虑实际的潜在碰撞时间距离。也就是说，在原始设计下，无论碰撞预计发生在 0.1 秒还是 1.4 秒后，都被同等对待。因此，该方法忽视了 TTC 作为紧迫性时间度量的核心含义，从而限制了其根据风险紧迫程度区分轨迹的能力。

**风格感知的时间阈值 TTC 在 SM-PDMS 中的应用** 为解决上述局限性，我们提出了一种改进的 TTC 评分机制，该机制明确引入了预测的碰撞时间（即碰撞时刻），并将其与考虑驾驶风格的阈值进行比较。对于每条轨迹方案，我们记录检测到潜在碰撞的最早未来时间步。该碰撞时间值随后将与根据假设驾驶风格确定的预设阈值进行比较：例如，激进驾驶员的阈值为 0.8 秒，中性驾驶员为 1.0 秒，保守驾驶员为 1.2 秒。

然后根据此比较分配一个二元得分：

- 如果碰撞时间大于或等于阈值，则认为该轨迹可接受，并得分为 1；
- 否则，被认为不安全，得分为 0。

该方法在保持二元评分简单性的同时，引入了时间敏感性和个性化风险容差，从而使 TTC 指标更贴近驾驶风格偏好和人类驾驶行为。

## 1.4 其他子指标、汇总和备注

其他与安全相关的子指标包括 Navsim Dauner et al. [2024] 中定义的 NC 和 DAC，我们还保留了 Navsim 对所有子指标的聚合方法。

本文及其附录中提到的 PDMS 对应于 Navsim Dauner et al. [2024] 版本 1 的实现。

## 2 更多数据集统计量的演示可视化与图示

### 2.1 样式标注结果演示可视化

为了说明我们数据集中风格标注的有效性和多样性，我们在三个代表性场景中可视化了从相似初始位置出发的不同驾驶行为。如图 6 所示，车辆表现出明显可区分的激进、正常和保守驾驶倾向。

值得指出的是，这些有意义的风格差异得益于我们全面的建模与标注框架，以及原始 Open-Scene 数据集固有的丰富性。该数据集来自美国和新加坡不同驾驶员在多样且复杂的城市环境中驾驶的车辆，具有高度的环境多样性。

### 2.2 数据集统计量示意图

为了全面概述驾驶风格标注，我们可视化了在关键场景类型中 激进 (*A*)、正常 (*N*) 和 保守 (*C*) 标签的分布情况。每个饼图总结了特定行为情境下各风格所占比例。图 7a-7g 展示了在 11 个细粒度场景类别中的分布情况。

变道场景主要以正常驾驶行为为主 (85.1%)，激进和保守风格分别占 10.8% 和 4.1%。变道行为中，激进行为 (32.4%) 和保守行为 (12.7%) 所占比例相对较高，表明横向变道行为存在多样化的偏好。在人行横道场景中，正常驾驶行为仍占主导地位 (80.3%)，但激进 (14.7%) 和保守 (5.0%) 驾驶行为也较为显著。

在合并相关场景中，侧路汇入主路（主路）表现为 7.1% 的激进行为和 5.1% 的保守行为，而侧路汇入主路（侧路）则记录为 13.8% 的激进行为和 3.3% 的保守行为，剩余 82.9% 为正常行为。受保护交叉口的激进行为占比为 12.7%，略高于无保护交叉口的 12.2%，后者同时表现出 2.0% 的保守驾驶行为。

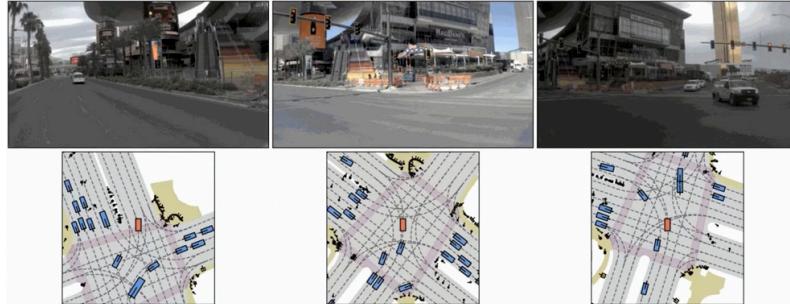
在环形交叉口，入口路段表现出 8.6% 的激进行为和 2.3% 的保守行为，而内部路段更为稳定，其中 91.4% 为正常行为，8.6% 为激进行为。特殊内部道路表现出更高的变异性，包括 37.3% 的激进行为和 3.9% 的保守行为。乡村道路总体保持稳定，正常行为占比 90.9%，仅观察到 6.2% 的激进驾驶行为。停车场区域的行为则完全为正常 (100.0%)。

## 3 面向更多样化场景的地图拓扑修改

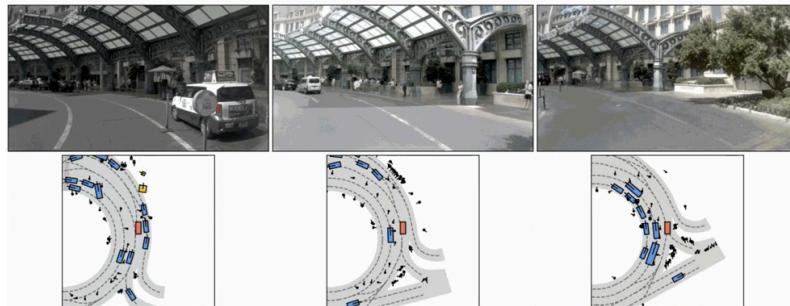
为提高静态场景分类的准确率，我们使用 QGIS 对 NuPlan HD 地图进行手动优化。这些调整针对原始拓扑中的已知缺陷，为行为建模提供了更具语义意义的基础。

**精细化交集语义。** 原始的交集定义过于粗糙。我们引入了细粒度的多边形标注，用于：

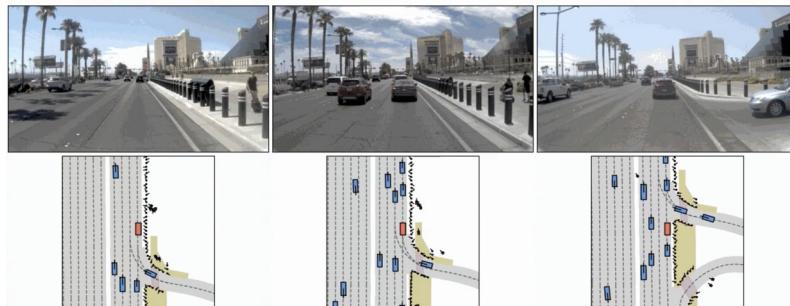
- 合并区域：小型道路（如支路或匝道）汇入主路的区域。这些区域通常存在视野障碍和并线风险。



(a) 在相同的初始条件下进行左转操作，7秒后，激进型驾驶员（左侧）表现出更高的加速度并取得了最大的前进距离，常规型驾驶员（中间）中等程度地向交叉口中心前进，而保守型驾驶员（右侧）启动缓慢，仅产生微小的位移。



(b) 在 内部道路场景 的相似初始条件下，7秒后，激进驾驶员（左侧）表现出更高的速度并取得了最大的进展，忽略了潜在的突然行人出现或车辆合并情况；正常驾驶员（中间）进展适中；而保守驾驶员（右侧）则缓慢且谨慎地前行，应对这一复杂场景。



(c) 在相同的初始条件下，针对侧路-主路场景（自行车位于主路），7秒后，激进驾驶员（左侧）无视汇入车辆，保持高速通过汇入点；正常驾驶员（中间）适度减速但仍优先于汇入车辆通过；而保守驾驶员（右侧）则与前车保持较大距离，甚至刹车以给汇入车辆让出空间。

图 6: 在三个代表性场景中，从相似初始位置可视化不同的驾驶行为。轨迹清晰地反映了激进（左）、正常（中）和保守（右）的驾驶倾向，展示了标注风格标签的有效性和多样性。

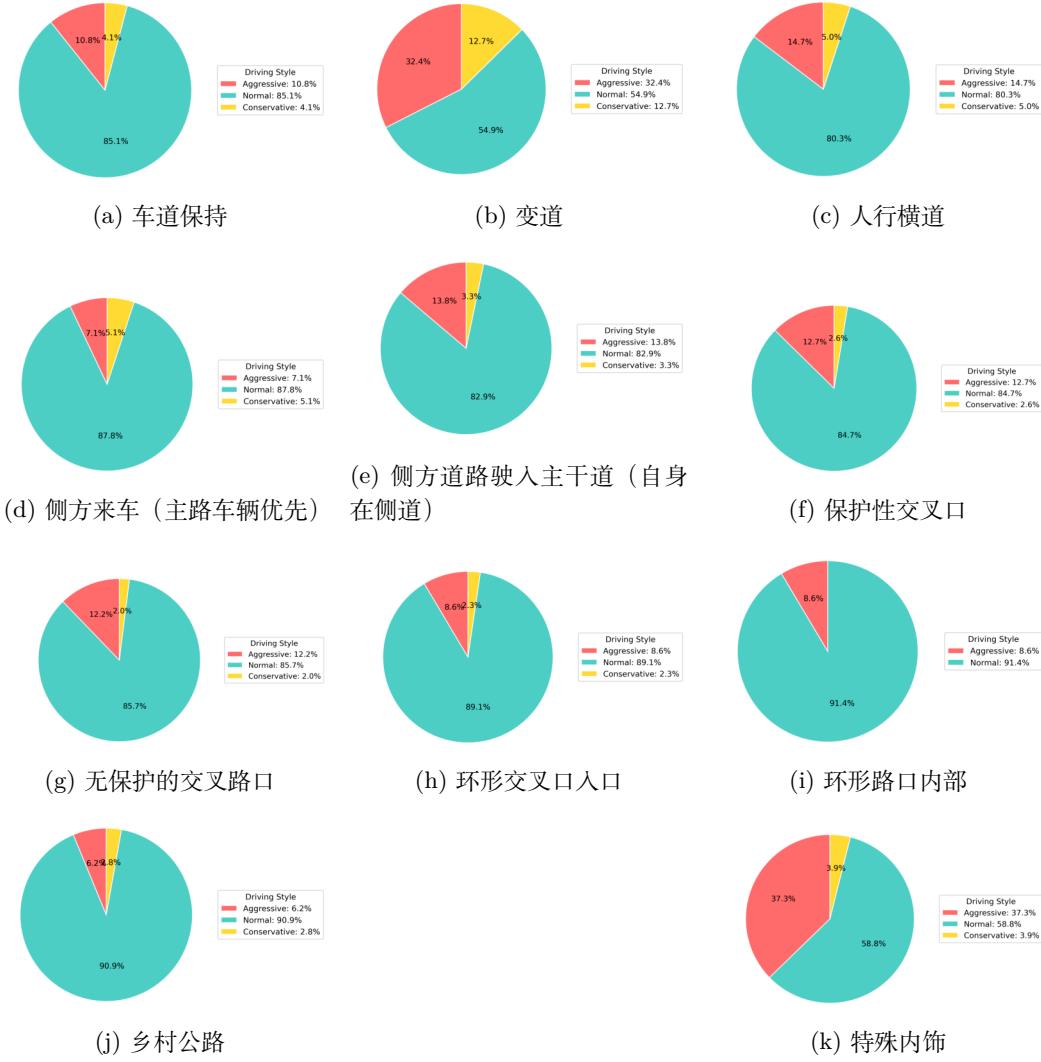


图 7: 按场景划分的标注驾驶风格分布 (A: 激进, N: 正常, C: 保守)。

- 主路合并接纳区：指主路沿线预计会从相邻车道或次级道路合流的区域。这些区域存在合流冲突和礼让挑战。

**功能区道路。** 我们为赌场、酒店、医院和机场等区域添加了内部道路多边形。这些环境具有不规则的几何形状，频繁停车，并与非标准道路智能体存在密集交互。它们通常伴随着低速行驶风险、视线遮挡以及高密度行人，对于评估慢速驾驶和谨慎驾驶风格至关重要。

**环形交叉路口特定区域。** 我们标注了环形交叉口的入口以及内部环道。这些区域容易出现路权判断错误、并线不当和出口延误等问题，给规划带来了不小的挑战。

**乡村道路。** 鉴于匹兹堡乡村道路独特的结构特征——如车道狭窄、标识有限以及弯道较急——我们将其单独划分，以更准确地捕捉相关的驾驶行为。

**交集规范化** 我们通过统一定义并分离控制逻辑（如停车标志与交通信号灯），对 NuPlan 的交叉路口类型进行标准化，从而实现下游场景标签的一致性。

## 4 关于基于规则与分布的启发式方法的偏好标注的更多细节

为提供一种透明且稳健的驾驶风格标注方法，我们详细说明了用于在多种交通场景下分类驾驶行为的启发式规则。这些规则基于通过系统性场景建模细化后的场景子类别制定，确保了上下文的相关性。在每个子类别中，对群体层面的行为分布进行分析，以统计方式推导出规则阈值。规则本身基于可解释且具有物理意义的特征，能够捕捉运动动态和上下文语义，如主论文所述。最终的阈值校准通过专家验证进一步优化，实现了场景特定、目标明确且可解释的偏好标注。

表 5 总结了构成我们基于规则的驾驶风格分类基础的动态特征、上下文变量和场景类型。这些标准指导着不同驾驶情境下的标签标注，从而在行为分析中实现一致性和可推广性。

在以下小节中，我们将详细阐述每种场景类型的规定设计。

### 4.1 车道跟随场景中的启发式方法

在车道保持场景中，驾驶风格根据运动动力学、道路几何形状以及与前车的交互情况被分为激进 (*A*)、正常 (*N*) 或 保守 (*C*)。我们的分类框架基于规则和分布，利用回归得到的速度趋势以及上下文感知特征来确定驾驶风格。

**速度趋势估计。** 对自车的速度曲线  $v(t)$  进行线性和二次回归拟合分析，以推导其变化趋势：

- 加速或减速：通过具有显著斜率的线性拟合捕捉；
- 先加速后减速或 先减速后加速：由非单调二次拟合捕捉；
- 准常数：当  $\text{std}(v(t))$  较低且无明显趋势时确定。

**上下文调制。** 趋势解读受道路形状——直线或弯道——以及前车存在与否的影响。对于存在前车的样本，我们定义了一个不安全跟车比例来表征高风险接近状态，同时定义了一个安全跟车比例来检测谨慎行为。这些阈值由经验数据统计自适应确定。

**规则与分布基础分类。** 最终的驾驶风格是根据速度趋势、平均车速、峰值加速度、加速度变化率以及安全距离比率来确定的：

- **激进 (A):** 当不安全跟车比例较高，或速度、加速度、变异度等运动信号显著超出正常值域时赋予。
- **保守型 (C):** 当自车保持低速、加速度变化小，或与前车始终保持较大距离时分配。
- **正常 (N):** 分配给不满足任一极端条件的样本。

该规则适应于 6 个子条件：[前车：近 / 远 / 无]  $\times$  [道路形状：直 / 弯曲]。在无前车情况下，分类仅依赖于统计运动描述符，而不进行基于距离的调制。

### 4.2 特殊内部道路场景中的启发式方法

在特殊内部道路场景中——其特征为狭窄车道、合并区域或行人密集区——驾驶风格通过自车运动趋势与局部交通语义的结合来确定。基于规则的框架结合了由上下文指示器（包括合并交互、前车存在及行人出现）调制的速度与加速度模式。

表 5: 基于规则的启发式准则用于跨场景驾驶风格分类

Traffic Scenario Type	Contextual Variants	Main Dynamic Features
Lane Following	Lead distance (Close/Far/None), Road shape (Straight/Curve)	Ego speed and acceleration trend, front vehicle proximity unsafe/safe frame ratio
Protected Intersections	Turn direction (Left/Right/Straight), pedestrian/lead presence	Ego speed, acceleration, front gap safety ratio turning intent and crossing semantics
Unprotected Intersections	Similar to protected, but without signal control	Speed and yaw change pattern, gap safety evaluation presence of pedestrian or lead car
Lane Change	Rear vehicle presence	Lateral dynamics ( $v_y$ , $a_y$ , yaw diff, rear threat)
Special Interior Road	Lead/pedestrian presence, merging complexity	Unsafe duration, deceleration behavior merge risk indicator
Side to Main Ego	With/without merging risk	Ego speed trend, lateral velocity, merging maneuver assertiveness
Side Ego to Main	Main road vehicle/pedestrian presence	Ego speed and acceleration under incoming vehicle threat
Crosswalks	Pedestrian presence	Ego speed and acceleration trend near crosswalk behavioral intent (e.g., yield or accelerate)
Roundabout Entrance	With/without yield/merge risk	Ego speed and entry maneuver stability, yield behavior to surrounding traffic
Roundabout Interior	-	Circular stability, lateral acceleration and smoothness of ego motion
Countryside Road	Road shape (Straight/Curve)	Ego speed, curvature following longitudinal and lateral acceleration smoothness

**速度趋势特征描述。** 通过使用线性与二次回归模型拟合速度序列  $v(t)$ , 分析了本车的纵向运动。根据模型残差和斜率系数, 趋势被分类为 加速、减速、准恒定或 非单调, 遵循相同的趋势提取过程。

**上下文调制。** 两种语义线索会影响规则的解读: (i) 前车的存在; 以及 (ii) 行人活动。这些指标会自适应地影响从数据集统计分布中得出的阈值。

**规则与分布基础分类。** 风格标签通过结合运动描述符和上下文信号来确定:

- **合并风险情景：**当加速度或速度模式明显强烈时，推断为 **激进 (A)** 行为；对于缓慢而稳定的合并运动，则归类为 **保守 (C)**。
- **有前车或行人时：**若本车在交互约束下表现出谨慎行为，则赋予 **保守 (C)** 行为；反之，紧跟和高运动信号则表明 **激进 (A)** 行为。
- **孤立场景 (无前车或行人)：**标签完全由运动统计量决定，使用从数据集整体轨迹分布中提取的阈值。

### 4.3 交叉路口场景中的启发式方法

交叉口场景——包括受保护的（如信号控制或停车控制）和不受保护的（如无信号控制或让行控制）路口——在空间和社会约束下涉及复杂的决策过程。在此类场景中，驾驶风格分类依赖于车辆的行驶意图、与周围智能体的交互风险以及运动动态。

**机动检测。** 通过车辆航向角随时间的变化推断主车的行驶工况类型。持续的方向变化表明转向操作（左转或右转），而航向角变化较小则表明车辆沿直线行驶。该工况分类影响对运动行为及风格阈值的解读。

**交互意识。** 交互风险通过语义线索（如前车和行人的存在）来确定。我们定义了一个不安全跟驰比，用以衡量自车相对于其速度是否保持了过小的车头间距。相反，我们也定义了一个安全跟驰比，用于捕捉特别谨慎的行为。这些量随时间计算，并用于调节风格推理。

**规则与分布基础分类。** 驾驶风格通过整合操作类型、交互上下文以及时间运动特征来确定：

- **激进 (A)：**当自车与前车之间的跟车距离不足、平均速度较高或加速度变化迅速时，可推断为激进行为。在转弯或存在行人的情况下，这种激进的动态特性会引发潜在的安全隐患。
- **保守型 (C)：**当自车与其他智能体保持较大间距、表现出平稳缓慢的运动，或始终维持安全距离时，判定为保守型。加速度变化趋势波动极小且跟车距离较大也表明了保守意图。
- **正常 (N)：**在行为未明显偏向攻击性或谨慎性的情况下分配，反映平衡的动态。

**场景类型调制。** 尽管分类规则是统一的，但其应用会受到交互情境的调节：

- **转向操作 (左/右)：**由于横向轨迹变化以及冲突交通频繁出现，风险升高。当车辆在近距离跟车情况下表现出激进的动态时，会呈现出激进分类；而谨慎避让或保持较大间距则表现为保守行为。
- **直线交叉：**风格微分由运动趋势（例如，加速、减速或匀速）与领先距离共同决定。
- **控制影响：**受保护的交叉口（例如交通信号灯）允许稍具攻击性的行为而无惩罚，而未受保护的路口则对谨慎行为有更严格的要求。

### 4.4 过街横道场景中的启发法

人行横道场景由于可能存在行人互动，需要提高警觉性，尽管通常不存在复杂的交通几何结构或前车。在此情境下，驾驶风格的分类仅依赖于自身车辆的运动特征以及行人的存在。

**上下文感知** 每个场景包含一个二元指示符 `pedestrians`，用于指定行人是否出现在人行横道附近。不考虑前车信息，且默认道路为直线。

**基于运动的特征。** 我们提取关键运动学特征：

- 平均速度  $v_{\text{avg}}$ ；
- 最大加速度  $a_{\text{max}}$ ；
- 加速度标准差  $\sigma_a$ ；
- 运动趋势（即 加速），通过在速度序列上使用线性回归检测得到。

**规则与分布基础分类。** 样式标签的分配如下：

- **攻击性 (A):** 若以下任一条件成立：

- $v_{\text{avg}} > \theta_v$ ;
- $a_{\text{max}} > \theta_a$ ;
- $\sigma_a > \theta_\sigma$ ;
- 运动趋势表明加速。

其中  $\theta_v$ 、 $\theta_a$  和  $\theta_\sigma$  为经验选择的阈值。

- **保守 (C):** 如果  $v_{\text{avg}}$  显著偏低（例如， $< 2.0$  m/s），无论其他指标如何。
- **常规 (N):** 其他所有情况。

#### 4.5 侧向汇入主路（主路车辆为本车）情形下的启发式方法

在侧向-主路场景中——即自车试图从支路合并至主路时——驾驶风格主要受间隙接受行为和并道激进程度的影响。这些场景要求实时决策以平衡谨慎与主动性，尤其是在并道压力下更为显著。

**合并上下文识别。** 场景通过二元指示符 `has_merging` 进行标注，表示在自车合并时主路车辆是否存在。这一上下文影响对速度和加速度的解读——在压力下采取激进的合并行为可能反映出对间隙评估不足。

**运动特征** 我们使用以下运动学属性来推断驾驶风格：

- 平均速度  $v_{\text{avg}}$ ；
- 最大总加速度  $a_{\text{max}}$ ；
- 纵向速度趋势（加速），通过线性回归估计。

**规则与分布基础分类。** 分类遵循以下逻辑：

- **攻击性 (A):**
  - 如果 `has_merging` 为 `True` 且  $v_{\text{avg}}$  或  $a_{\text{max}}$  为高电平，或者速度趋势表明正在加速；
  - 如果 `has_merging` 为 `False`，但  $v_{\text{avg}}$  或  $a_{\text{max}}$  为高电平，表示尽管没有合并压力，仍存在断言性运动。
- **保守 (C):** 若  $v_{\text{avg}}$  值较低，表明存在让行或缓慢合并行为，与合并情境无关。
- **正常 (N):** 动态适中且无加速度突变的其余所有情况。

## 4.6 侧路并入主路（主车在侧路）情形下的启发式方法

在侧路-主路场景中——即自行车位于主路，可能遇到来自侧路的合流交通——驾驶风格反映了自行车在潜在合流冲突中导航时的激进或谨慎程度。这在评估风险规避或对先行权的主导性时尤为相关。

**交互上下文。** 关键语义指示符 `main_road_vehicles` 表示是否存在合流交通。尽管也可能存在行人，但分类主要关注自行车在应对合流活动时的动力学行为。

**主要特征。** 我们使用以下特征来推断行为：

- 平均速度  $v_{\text{avg}}$ ；
- 最大加速度  $a_{\text{max}}$ ；
- 加速度标准差  $\sigma_a$ 。

**规则与分布基础分类。**

- **激进 (A)：**若平均速度和峰值加速度均较高，则分配该标签，即在合并情形或一般情况下，主体车辆保持主动的前向运动。这包括以下模式：

$$v_{\text{avg}} > \tau_v^A, \quad a_{\text{max}} > \tau_a^A$$

其中  $\tau_v^A$  和  $\tau_a^A$  为经验设定的阈值。

- **保守型 (C)：**如果自行车表现出持续的低平均速度和稳定的加速度，表明其采取谨慎的行驶策略，则被归为此类：

$$v_{\text{avg}} < \tau_v^C, \quad \sigma_a < \tau_\sigma^C$$

- **正常 (N)：**介于两者之间的所有情况，速度适中，加速度曲线既不激进也不保守。

## 4.7 变道场景中的启发式方法

变道场景涉及动态且可能具有高风险的横向操作，要求本车在运动过程中与邻近车辆协调。在此情境下，驾驶风格由意图方向（左或右）、空间约束（如前后车辆的存在）以及横向速度和加速度变化等运动特性决定。

**方向与后方车辆感知。** 预期的变道方向通过偏航角变化  $\Delta\psi$  推断：当  $\Delta\psi > 0.25$  弧度时检测到左变道，当  $\Delta\psi < -0.25$  时检测到右变道。目标车道中后方车辆的存在由场景指示符 `has_left_rear` 和 `has_right_rear` 表示。此外，如前方车辆的接近程度等其他指示符用于确定紧迫驱动的 maneuvers。

**运动指示器。** 以下动态特征被提取以表征机动强度和稳定性：

- 最大绝对横向速度： $v_y^{\text{max}} = \max |v_y|$ ；
- 平均纵向速度： $v_{\text{avg}}$ ；
- 最大加速度： $a_{\text{max}}$ ；
- 加速度标准差： $\sigma_a$ ；
- 机动过程中的偏航差： $\Delta\psi$ 。

**规则与分布基础分类。** 规则因变道方向及后方是否有车辆而异：

- **攻击性 (A):**

- 左侧变道与后方车辆：若  $a_{\max}$ 、 $\sigma_a$  或偏航角变化  $\Delta\psi$  中任意一项超过阈值——无论速度如何——均表示在高风险情境下出现急剧运动；
- 左侧变更且后方无车辆：仅当  $v_{\text{avg}}$  为高电平，且  $a_{\max}$ 、 $\sigma_a$  或  $\Delta\psi$  中至少有一个为大时；
- 右变道伴随后车：与左变道类似——如果  $a_{\max}$ 、 $\sigma_a$  或  $\Delta\psi$  为高电平，标记为激进；
- 右侧变更车道且后方无车辆：必须满足  $v_{\text{avg}}$  为高电平且  $a_{\max}$ 、 $\sigma_a$  或  $\Delta\psi$  中任意一个为高电平。

- **保守派 (C):**

- 左侧变化：当  $\Delta\psi$  和  $\sigma_a$  均为低电平时，表示方向平滑切换；
- 右转：当  $\Delta\psi$  和  $v_{\text{avg}}$  均为低电平时，表示柔和且受控的运动。

- **正常 (N):** 适用于不表现出极端行为的样本的默认情况。

## 4.8 乡村道路场景中的启发式方法

乡村道路场景的特点是交通密度低、限速宽松，但可能存在较大的几何形态变化，例如长直路段和急转弯。这些条件赋予驾驶行为更大的自由度，因此需要制定分类规则，以区分允许的巡航行驶与可能带来危险或过于消极的驾驶操作。

**几何分类** 每个场景根据地图拓扑结构和轨迹形状被标注为 Straight 或 Curve。这种二分类有助于理解运动行为，因为弯曲的道路通常需要更紧密的控制和更高的谨慎程度。

**运动特征** 我们提取以下自我动态指标来推断驾驶风格：

- 平均速度  $v_{\text{avg}}$ ；
- 最大加速度  $a_{\max}$ ；
- 加速度标准差  $\sigma_a$ 。

**规则与分布基础分类。** 规则在直线路段和弯曲乡间情景中保持一致，风格分配如下：

- **激进 (A):** 若任意运动指标—— $v_{\text{avg}}$ 、 $a_{\max}$  或  $\sigma_a$ ——超过预设阈值，则标注为激进，表明存在主动或潜在不稳定行为，与道路几何形状无关。
- **保守型 (C):** 当两者  $v_{\text{avg}}$  和  $\sigma_a$  均较低时分配，反映进展缓慢且平滑，与谨慎行为一致。
- **正常 (N):** 速度和变异性适中，介于两个极端之间的情况的默认标签。

## 4.9 环岛入口情境中的启发式方法

环形路口入口场景涉及在潜在合流压力下的复杂操作。驾驶风格根据自车速度模式、加速度行为以及上下文合流风险，分为激进 (A)、正常 (N) 或 保守 (C)。采用基于规则的策略以确保可解释性与上下文敏感性。

**上下文调制。** 每个场景都用一个二值指示符 `merge_risk` 进行标注，用于表示周围车辆是否可能与本车同时汇入环形交叉口。该标志调节激进程度的阈值：当存在汇入风险时，即使较为自信的行为也可能被视为激进，而谨慎进入则被强调为保守行为。

**动态特征。** 分类基于一系列行为指标，包括：

- 自车的平均速度和纵向加速度模式；
- 加速度的变异性，作为控制平稳性的代理指标；
- 通过时间拟合得出的速度趋势（例如，加速、减速、准恒定）。

**规则与分布基础分类。** 驾驶风格通过运动动力学与上下文语义的联合评估来确定：

- **合并风险：**

- 激进式 (*A*)：当自车表现出激进的加速行为或与快速切入相关的非单调趋势时识别为该类型；
- 保守 (*C*)：若车辆保持缓慢、平稳的行驶状态，或在合并前表现出明显的减速，则被赋予此评分；
- 剩余的行为被标注为 **正常 (N)**。

- **无合并风险：**

- 激进 (*A*)：适用于高速或强加速进入的情况，即使在低风险情景中也是如此；
- 保守型 (*C*)：适用于低速和平滑的轨迹；
- 中间行为默认为 **正常 (N)**。

## 5 基准方法的训练细节与视觉语言模型的微调

### 5.1 基准方法训练详情

所有基准模型均在配备  $8 \times$ NVIDIA A100 GPU 和双 AMD EPYC 7742 64 核 CPU 的 Linux 服务器上进行训练。每个独立模型使用两块 A100 GPU 进行训练，批量大小固定为 64。对于包含风格条件的模型，其训练轮数与无风格条件的对应模型保持一致，并设置为原始朴素基准模型所使用的轮数，以确保在所有情景下进行公平比较。

关于最优化，DiffusionDrive Liao et al. [2025] 和 DiffusionDrive-Style 的学习率均设置为  $6e-4$ 。对于 AD-MLPZhai et al. [2023]、Transfuser Chitta et al. [2022]、WoTE Li et al. [2025] 以及它们的风格条件变体（AD-MLP-Style、Transfuser-Style、WoTE-Style），学习率均统一设置为  $1e-4$ 。

### 5.2 视觉语言模型微调以提升驾驶场景理解的详细信息

为了在驾驶场景中实现准确且上下文敏感的语义推理，我们使用轻量级参数高效微调 (LoRA) 对 Video-LLaMA3 模型 Zhang et al. [2025] 进行微调。该过程使模型更好地理解在通用视觉-语言预训练中代表性不足的自动驾驶场景。

**训练数据。** 我们基于 LingoQA 数据集 Marcu et al. [2024]，这是一个多模态基准，包含视频片段和以道路语义、交互作用及意图识别为重点的场景级问答对。该数据集包含约 267.8k 个视频-提示-响应三元组，涵盖了多样化的拓扑结构和行为案例。

**模型设置。** 我们选用 Video-LLaMA3 作为基础模型，因其具备强大的多模态推理能力和开源支持。在微调方面：

- 我们冻结了视觉编码器和大多数 Transformer 层。

- 我们在选定的注意力层的查询和值投影矩阵中插入 LoRA 适配器。
- 我们在 6 块 A100 GPU 上训练 3 轮，学习率为  $1e-4$ ，批量大小为 96。
- 微调在不到 8 个 GPU 小时的时间内完成，使其适合大规模部署。